01 / PROJECT OVERVIEW

H&M 销售、客户复购与销量预测

基于公开交易样本的 SQL 分析与 Python 历史回测。观察期：2018-09-20 至 2020-09-22。

分析规模	结果
购买记录 / 连续观察天数	31,788,324条 / 734天
有成交客户 / 有成交商品	1,362,281人 / 104,547个
分析工具	MySQL、Python、pandas、statsmodels、Matplotlib
验证与测试	6种模型；5轮验证；最后28天测试

核心发现

销售：2020年1-8月销售额同比下降11.95%，件数下降13.02%。渠道2贡献观察期75.62%的销售额，但2020年春季渠道结构明显变化。

商品：前三大服装类贡献约79.04%的销售额；前约10%的有成交商品贡献61.67%的销售额，存在较高头部集中度。

客户：完整30天观察窗口复购率为28.13%；首次观察购买日之后的交易贡献84.41%的件数和84.25%的销售额。

预测：验证集选择ARMA，测试MAE却比简单基准高25.48%；SARIMA在该测试窗口MAE最低，WAPE为10.26%。验证与测试排名不一致，反映出模型表现对时间窗口的敏感性。

项目回答的问题

销售规模如何变化？哪些品类和商品贡献主要销售？哪些客户再次购买、多久回来？基于历史日销量的固定模型能否超过简单预测基准？

本文中的销售额是标准化价格之和，不能标注货币单位。所有结论仅适用于该数据集；业务建议未经上线或实验验证。

数据范围、指标口径与核验

数据来源：Kaggle 的 H&M Personalized Fashion Recommendations 竞赛。使用商品表、客户表和交易表。

原始表	记录数	粒度与用途
articles	105,542	每个商品编号一行，提供品类信息
customers	1,371,980	每个客户编号一行，提供年龄等属性
transactions_train	31,788,324	购买记录，包含日期、客户、商品、价格和渠道

指标定义

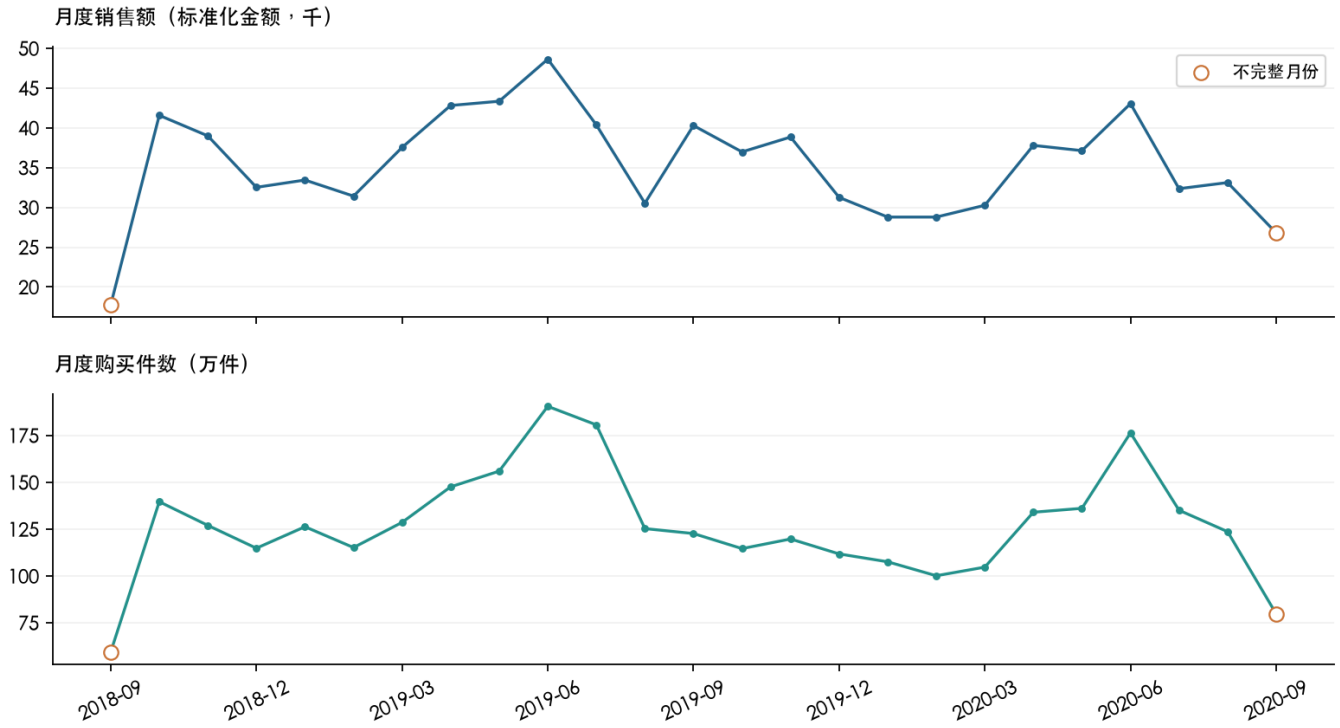
指标	定义 / 边界
销量	交易行数按购买件数统计；没有订单编号，不能当作订单数。
月购买客户	当月去重客户数；跨月或跨渠道相加会重复计数。
复购	在首次观察购买日之后的不同日期再次购买。
限期复购率	只纳入有完整后续窗口的客户；第1-30/90/180天内是否再次购买。
首购归属	首购日金额最高的渠道×大类组合；后续购买可跨品类、跨渠道。
年龄	客户表中的静态属性，不保证是购买当时年龄。

已经完成的核验

基础表编号非空、唯一，空字符串编号为0；交易未匹配客户、商品均为0；734天每天都有记录。年龄缺失15,861人（1.16%），其余16-99岁，代码定义的非正年龄为0。

24份SQL导出表的主要总量一致：月度、渠道、品类、新老客户销量均为31,788,324件。三种客户分组均合计1,338,029位30天合格客户、376,347位30天复购客户。

同期销量下降，月度高点并不等于持续增长



来源：monthly_overall_performance.csv。首尾月份不完整，以空心点标记。

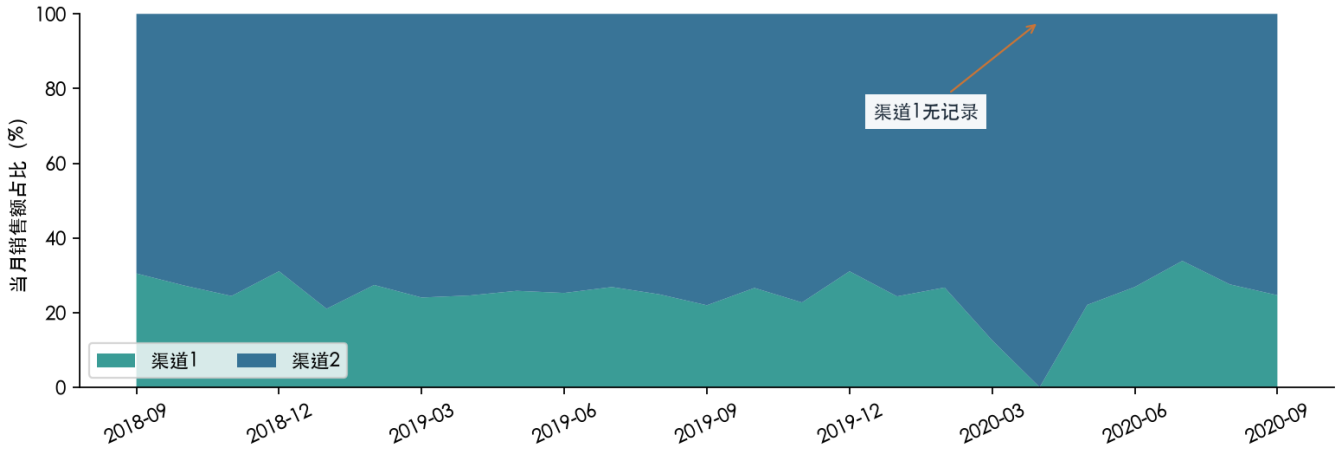
可比期间	标准化销售额	购买件数
2019年1-8月	308,191.107	11,706,632
2020年1-8月	271,363.710	10,181,863
同比变化	-11.95%	-13.02%

同期平均每件成交价格约上升1.24%。按照销售额=件数×平均每件价格，件数下降是主要数量变化，但均价变化可能涉及商品构成，不等于统一涨价。

2019年6月销售额48,648.418、销量1,906,202件，均为月度最高。该月销售额环比+12.20%，购买客户+12.39%，人均消费-0.16%，增长主要伴随购买人数扩大。

2018年10月与不完整9月比较、2020年9月与完整8月比较均需谨慎；比较月度总量时还应考虑月份天数。未根据这些变化推断促销或疫情因果效果。

渠道2贡献主要销售，渠道结构存在阶段性变化



来源：monthly_channel_performance.csv。图中渠道1在2020年4月为0表示无该月交易记录，不代表已经确认停业。

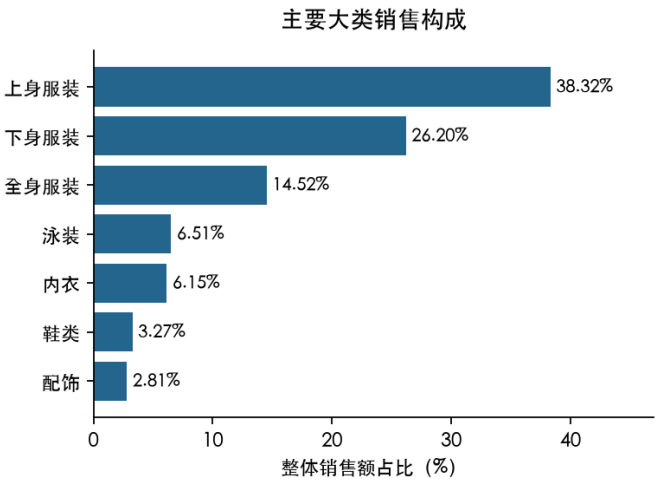
指标	渠道1	渠道2
全时期销售额占比	24.38%	75.62%
全时期件数占比	29.60%	70.40%
上身服装占渠道销售额	44.96%	36.18%
全身服装占渠道销售额	9.74%	16.07%
泳装占渠道销售额	3.72%	7.41%

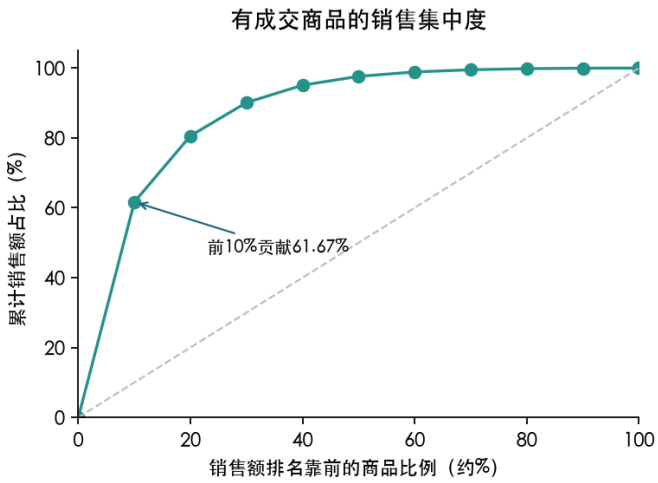
渠道2销售额占比高于其件数占比，意味着平均每件成交价格较高；渠道之间品类结构不同，也可能解释一部分均价差异。不能由此断言渠道2利润率更高。

渠道2月销售额占比从2020年2月73.29%，升至3月87.42%、4月100%，5月回到77.94%。应优先核查交易覆盖和渠道业务背景，再解释这次变化。

重要限制：渠道1的2020年5月增长115.14%实际上与3月比较，因为LAG跳过无记录的4月。

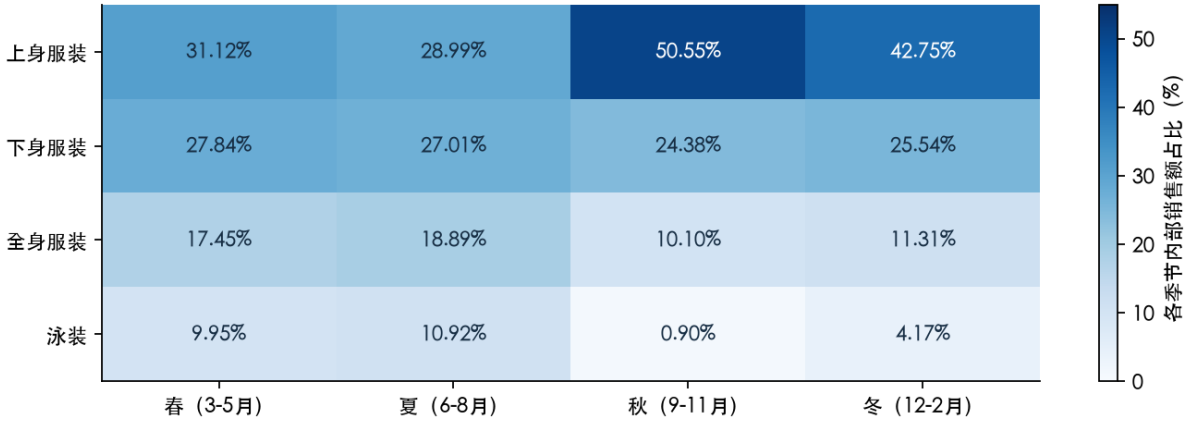
服装贡献主要销售，少数商品贡献多数销售额





来源：category_sales_structure.csv、product_sales_concentration.csv。集中度仅基于有成交商品。

上身、下身、全身服装分别贡献38.32%、26.20%、14.52%，合计约79.04%。前约10%的10,455个有成交商品贡献61.67%销售额，前约20%贡献80.60%。

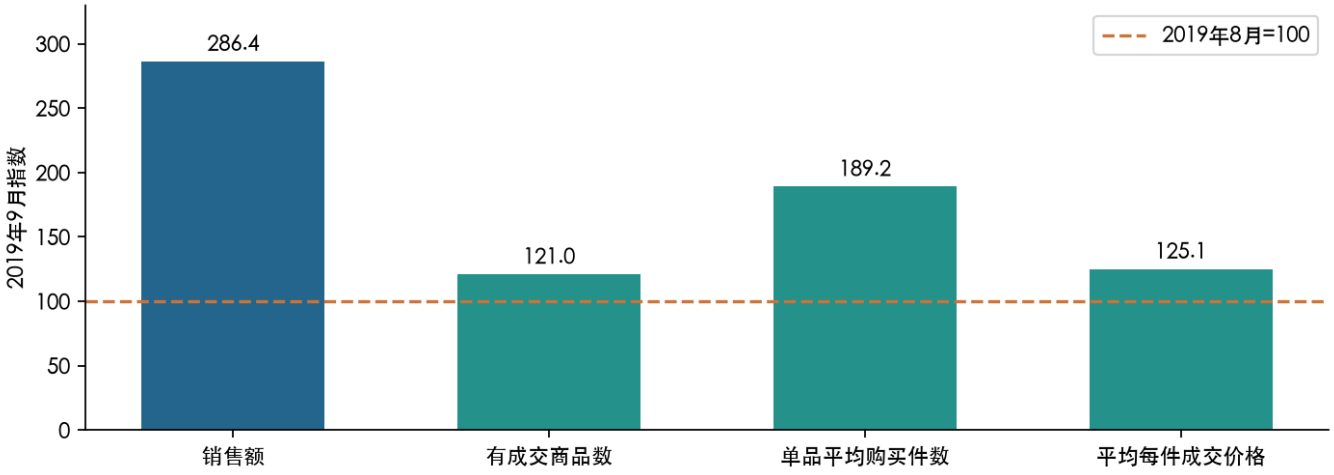


来源：seasonal_category_sales_structure.csv。按日历月份定义四季，合并不同年份。

上身服装在秋冬结构中占比较高；泳装和全身服装在春夏占比较高。建议按渠道、季节监控核心品类，优先检查头部商品供货，但没有库存、毛利和上市时间，不直接提出淘汰长尾或增加具体备货量。

季节覆盖天数不完全相同，仅据占比讨论结构。

从品类排名进一步拆解增长来源



来源：monthly_product_type_performance.csv。所有指标以2019年8月=100。

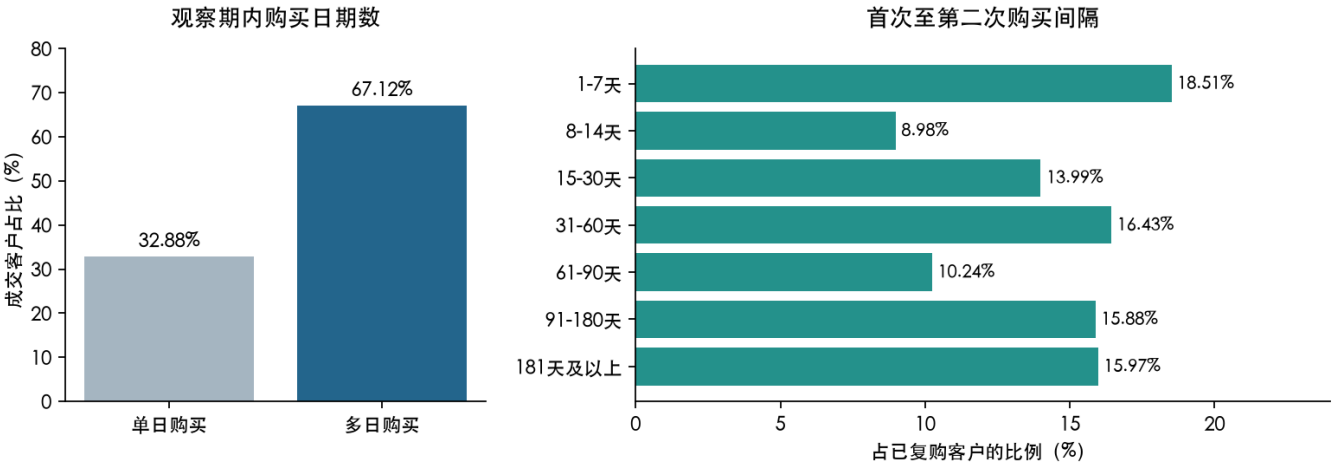
Sweater在2019年9月销售额环比增长186.44%；有成交商品数增长21.03%，每个成交商品平均销量增长89.17%，平均每件成交价格增长25.11%。三者为乘法关系，不能将增长率直接相加。

头部10%商品中的大类	商品数	占头部商品销售额
上身服装	4,007	35.97%
下身服装	2,676	30.65%
全身服装	1,828	14.49%
泳装	746	8.51%

下身服装与泳装在头部商品销售额中的占比，高于它们在全体销售中的占比。可以把这些品类的头部商品列入重点监控。

月度结构也显示变化：完整月份中，泳装占比2019年6月为15.17%，11月为0.51%。

复购是主要销售来源，但要区分观察期限



来源：customer_repurchase_overview.csv、second_purchase_interval_distribution.csv。右图只包含已观察到复购的客户。

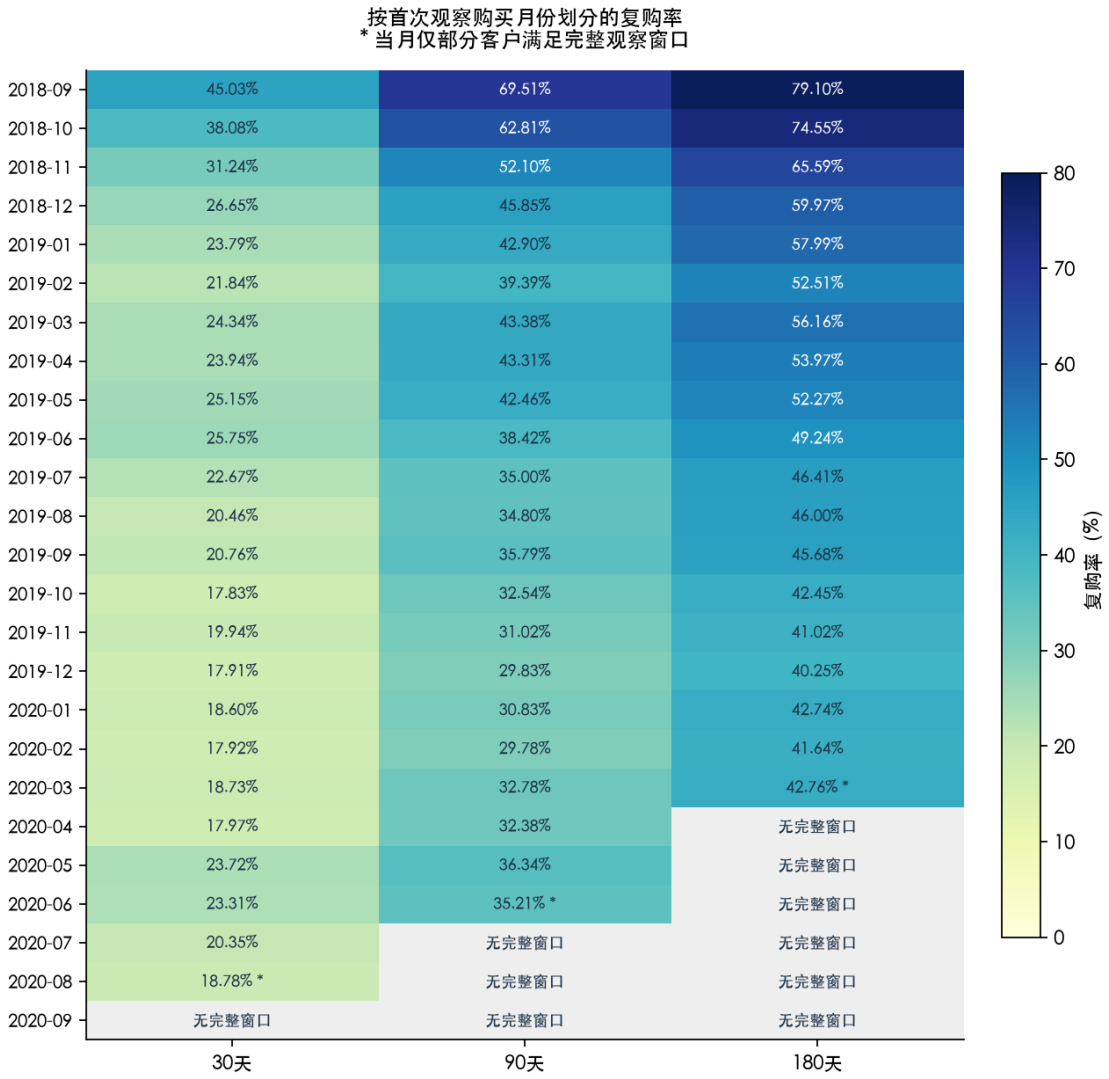
指标	结果	分母 / 口径
30天复购率	28.13%	1,338,029位完整30天窗口客户
90天复购率	47.07%	1,291,147位完整90天窗口客户
180天复购率	59.95%	1,189,917位完整180天窗口客户
二次购买间隔	中位数44天；均值90.59天	914,308位已观察到复购客户

已复购客户中，41.48%在30天内第二次购买，57.91%在60天内。

首次观察购买日之后的交易贡献26,832,675件，占总件数84.41%，占总销售额84.25%。这支持把客户后续购买列为重要分析方向。

同一客户首购日计入new，之后日期计入existing。

首购月份之间的复购表现存在差异

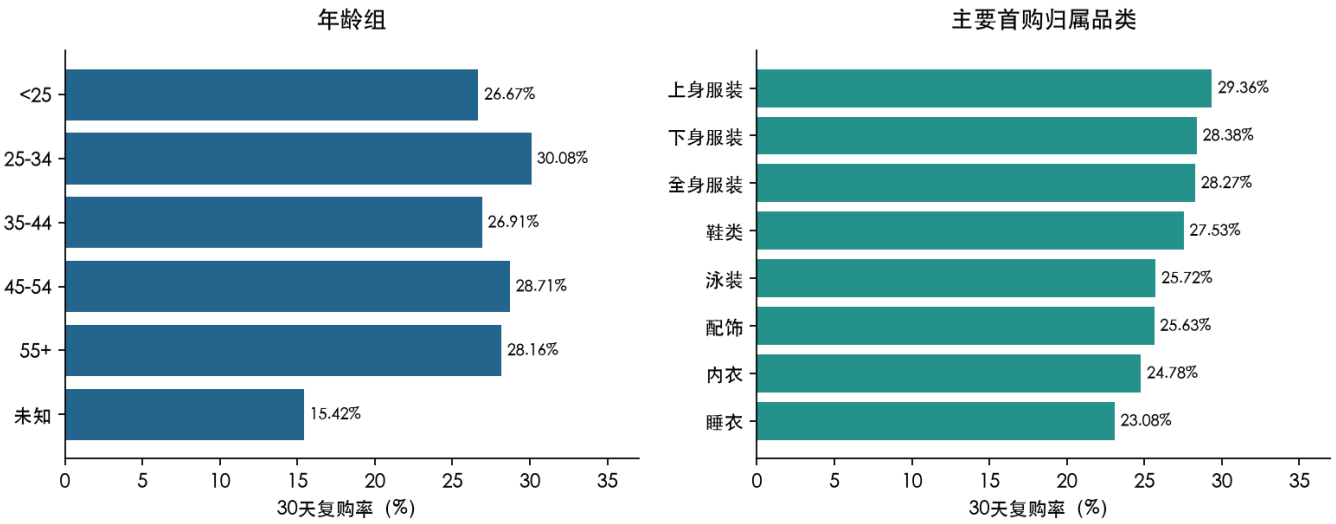


来源：monthly_cohort_repurchase_rates.csv。灰色表示没有符合完整窗口的客户。

2019年各月份30天复购率在17.83%-25.75%间波动；2020年5月从4月17.97%回升至23.72%。

2020年8月22,974位首次观察购买客户中，仅16,260位满足30天窗口，18.78%只代表这部分客户。2020年3月180天、6月90天也为部分覆盖。

复购率、客群规模与贡献应同时评价



来源：age_group_30d_repurchase.csv、first_category_30d_repurchase.csv。品类图只列主要品类，完整结果另存。

首购归属渠道	30天合格客户	30天复购客户	复购率
渠道1	463,219	138,825	29.97%
渠道2	874,810	237,522	27.15%

渠道1复购率高2.82个百分点，但渠道2复购人数更多。25-34岁组复购率30.08%，比<25岁高3.41个百分点；该组复购人数115,942人，在年龄组中也最多。

首购归属上身服装有571,765位合格客户，30天复购率29.36%，可作为较大客群的细分研究重点。Interior textile虽达到50%，但仅2位客户，不应按百分比直接排名推荐。

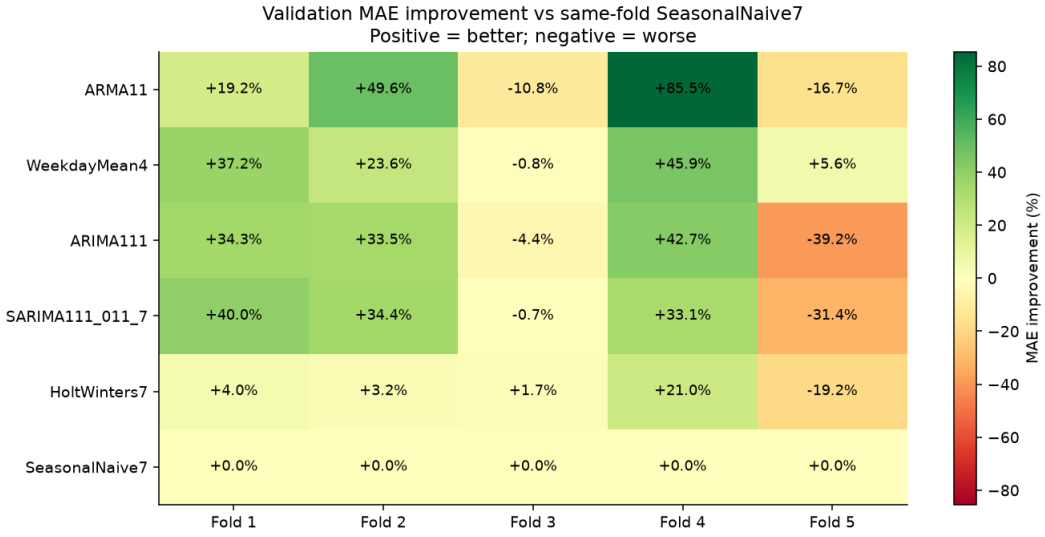
差异可能来自首购月份、品类、年龄和渠道结构，未进行因果识别。首购归属按最高金额的渠道×品类组合确定，后续复购可以跨品类与渠道。年龄unknown不是实际年龄段。

用历史回测比较金融时间序列与零售基准

目标是预测样本日购买件数。每次一次性预测未来28天，期间不读取真实销量更新模型。使用5轮扩展训练窗口验证，按平均MAE选模型，再评估固定测试期。

模型	固定设置
SeasonalNaive7	重复最近一周销量
WeekdayMean4	最近4周同一星期几的平均值
ARMA11	ARMA(1,1)，含常数
ARIMA111	ARIMA(1,1,1)，无趋势常数
SARIMA111_011_7	SARIMA(1,1,1)(0,1,1,7)
HoltWinters7	7天加性季节、加性阻尼趋势

验证覆盖2020-04-08至2020-08-25，分为5个连续、不重叠的28天窗口。最终训练截止2020-08-25，测试为2020-08-26至2020-09-22。所有模型统一非负预测约束。



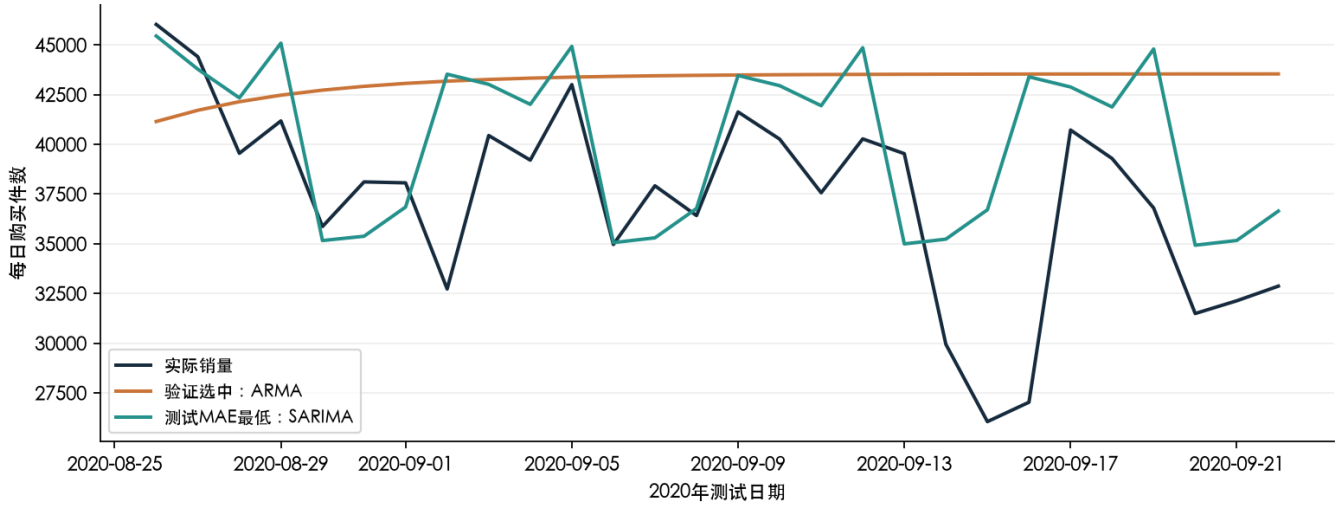
每轮相对同一轮季节性朴素基准的MAE改善；正数更好，负数更差。

ARMA验证平均MAE最低，为10,768.91件，但只在5轮中的3轮胜过基准，第4轮改善85.46%。平均排名掩盖了时间窗口之间的差异。

MA是过去预测误差项，不是普通销量移动平均。本实验比较固定设置，并非各模型家族最优参数；重跑已经看过的测试窗口属于复现，不是新的独立盲测。

验证最优模型未在测试期保持优势

模型	MAE / 件	WAPE	相对基准MAE改善
SARIMA	3,823.29	10.26%	+25.66%
Holt-Winters	3,875.46	10.40%	+24.65%
ARIMA	4,254.99	11.42%	+17.27%
SeasonalNaive7	5,143.29	13.80%	基准
WeekdayMean4	6,414.73	17.21%	-24.72%
ARMA（验证选中）	6,453.82	17.32%	-25.48%



来源：run_02/test_actual_vs_forecast.csv。测试实际总销量1,043,390件，日均37,263.93件。

ARMA在28天中有26天高估，总量高估15.87%；后期预测接近每天43,500件，未能跟随实际日销量的下降。SARIMA测试MAE最低，但Holt-Winters的RMSE最低。

季节性朴素法总量仅低估1.61%，但WAPE为13.80%。

WAPE=每日绝对误差之和/实际总销量；MASE7分母来自训练期。

业务建议、项目限制与复现路径

建议	证据	后续如何验证
监控核心商品与季节品类	前10%商品贡献61.67%销售额	补充库存、供货、上市时间和毛利，评估断货与长尾价值
分群研究首购后触达	30天复购28.13%；客群表现不同	设置随机对照实验，比较复购与增量利润，不能只看触达后的复购
核查渠道覆盖变化	渠道1在2020年4月无记录	确认数据覆盖、渠道业务背景后再解释结构变化
持续对照简单预测基准	验证最优ARMA测试劣于基准	用新时期或嵌套时间验证评估调参，监控偏差方向

限制需要跟随结论呈现

没有订单编号、实际货币单位、利润、库存、促销标签和明确市场范围。首尾月份不完整；首购是首次观察，部分客户观察窗口不足；分组差异未做因果识别。渠道1在2020年5月及细分类32处LAG跨月不能按普通环比解释。

交付内容与复现

SQL：code/01至05依次覆盖数据质量、销售概览、商品、复购、日销量导出。先导入三张原始表；复购临时表与@data_end必须在同一MySQL连接使用。SQL结果位于results/。

Python：forecasting/run_forecasting.py为完整入口；backtest.py实现模型与回测，analyze_forecasts.py保存分析。run_02保留36组评分、1,008条预测、图表、日志、输入快照和版本信息。重跑与run_01的MAE逐项一致。

详细证据见sql_analysis_findings.md与python_analysis_findings.md；README提供目录、操作说明和结果索引。GitHub代码包不包含3.2GB原始交易CSV或本地虚拟环境，代码包已发布在本仓库。

数据来源与归属

Kaggle：H&M Personalized Fashion Recommendations
https://www.kaggle.com/competitions/h-and-m-personalized-fashion-recommendations/data
本项目是个人分析作品，不代表H&M官方观点。原始数据从竞赛页面获取，并遵守其访问与使用条件。